

SU MARC

AI Engineer · Data Scientist · Risk / Fraud Data Scientist · ML Engineer

Bondy 93140, France · Permis B

sumarc183@gmail.com

github.com/sumarc183-design

Langues : Français (courant) · Anglais (B2) · Chinois (courant)

Tél. : +33 7 64 69 54 53

Disponibilité : immédiate — recherche CDI

linkedin.com/in/marc-su-698830400



PROFIL

Data Scientist / ML Engineer en Master 2 de modélisation mathématique appliquée à la finance et à la data (Paris 1 Panthéon-Sorbonne). Actuellement Intern chez Malakoff Humanis, je conçois et mets en production des modèles de détection de fraude (Dataiku DSS, Snowflake, MLflow). J'aime aller du besoin métier au modèle déployé, fiable et documenté. Je recherche un poste en CDI en AI Engineer, Data Scientist, Risk / Fraud Data Scientist ou ML Engineer.

EXPÉRIENCE PROFESSIONNELLE

Data Scientist / ML Engineer — Intern (détection de fraude)

avr. 2026 – oct. 2026 · en cours

Malakoff Humanis — Paris · Périmètre : réseau optique (lentilles & lunettes) en assurance santé

- Détection de fraude sur prestations optiques : cycle complet du besoin métier à la mise en production sur Dataiku DSS, Snowflake et MLflow.
- Feature engineering et prévention des fuites de données ; classes d'âge apprises par arbres (train uniquement) puis figées (train / test / API).
- Comparaison XGBoost / Random Forest / régression logistique en validation temporelle ; métriques ROC-AUC, recall, F1, matrice de confusion et lift.
- Industrialisation en pipelines MLflow autonomes (préparation + classification), signés et déployés en API Dataiku, testés depuis les champs bruts.
- Monitoring en production : contrôle hebdomadaire de l'enrichissement temps réel des variables clés — clés manquantes, échecs, dérive.
- Résultats** : ROC-AUC $\approx 0,745$ et lift décile $\approx 1,79$ (lentilles), $0,695 / 1,70$ (lunettes) — ciblage $\sim 79\%$ plus efficace qu'un tirage aléatoire.
- Livrables : modèle exporté, variables clés (explicabilité) et documentation pour le déploiement.

Gérant — commerce Bar-Tabac

en cours

Gestion des flux financiers et d'opérations sensibles dans le respect des procédures réglementaires ; relation client et organisation.

PROJETS

FraudScope AI — assistant d'investigation de fraude (GenAI + ML)

Python · LangGraph

Agent GenAI (RAG hybride Qdrant dense+BM25, function calling, LangGraph) au-dessus d'un pipeline ML de scoring de fraude (XGBoost / Random Forest) : explique le score, cite les règles réglementaires. Stack : FastAPI, Streamlit, Langfuse, Docker.

Deep Learning & NLP — parcours de projets (from scratch → Transformers)

Python · PyTorch

Parcours progressif en deep learning appliqué au NLP : réseaux from scratch (NumPy / PyTorch), word embeddings, RNN / LSTM, Transformers (attention, fine-tuning CamemBERT) et pipeline RAG (FAISS, embeddings sémantiques).

GovProcure AI — Python · Plateforme d'analyse des marchés publics français (3,14M contrats open data) : contrôle qualité, détection d'anomalies (Isolation Forest / LOF) et recherche hybride BM25 + embeddings + RRF ; 69 tests, CI GitHub Actions.

Séries temporelles — Python · Étude de stationnarité (ACF / PACF), modélisation ARIMA / SARIMA, prévision et backtesting sur données réelles.

Modélisation stochastique & propagation — Python · Modèle épidémiologique SIR et ses extensions, phénomènes de percolation sur graphes, simulations Monte-Carlo et optimisation des paramètres.

Jeu Mastermind — Python · Résolution algorithmique par arbre de décision et élagage ; optimisation des stratégies (minimax, heuristiques).

FORMATION

Master 2 — Modélisation et Méthodes Mathématiques en Économie et Finance (MMMEF), parcours Data

2024 – 2026

Université Paris 1 Panthéon-Sorbonne — en cours · Data science et big data, fondements mathématiques du machine learning, optimisation (programmation linéaire et combinatoire), statistique asymptotique, méthodes numériques et programmation (Python, C++), séries temporelles, modélisation stochastique.

Licence de Mathématiques (option informatique)

2021 – 2024

Université Paris-Saclay · Analyse, probabilités et statistiques, méthodes numériques, programmation Python.

COMPÉTENCES & CENTRES D'INTÉRÊT

Programmation & data : Python, R, SQL, Java, JavaScript, C — pandas, NumPy, Scikit-learn, XGBoost.

Data science & MLOps : machine learning, IA générative, feature engineering, MLflow, CI/CD, monitoring, PSI / dérive, API de scoring, pipelines de production.

Plateformes & BI : Dataiku DSS, Snowflake, Power BI, Git / GitHub / GitLab, Linux ; Jira, Trello.

Soft skills : esprit analytique, capacité à vulgariser, rigueur, autonomie, travail en équipe.

Centres d'intérêt : IA & innovation numérique · data science · veille technologique · badminton · musculation (1 séance/semaine).