

# SU MARC

Data Scientist Finance · Risk Data Scientist · Quantitative Analyst · AI Engineer

Bondy 93140, France · Permis B

sumarc183@gmail.com

github.com/sumarc183-design

Langues : Français (courant) · Anglais (B2) · Chinois (courant)

Tél. : +33 7 64 69 54 53

Disponibilité : immédiate — recherche CDI

linkedin.com/in/marc-su-698830400



## PROFIL

Data Scientist en Master 2 de modélisation mathématique appliquée à la finance (Paris 1 Panthéon-Sorbonne), je transforme la donnée en décisions concrètes pour maîtriser le risque. Actuellement Intern chez Malakoff Humanis, sur la détection de fraude en assurance santé, je construis des modèles de scoring du risque. Je sais dialoguer avec les équipes métier, prioriser ce qui a de la valeur et livrer des résultats mesurables. Je recherche un poste en CDI.

## EXPÉRIENCE PROFESSIONNELLE

### Data Scientist — Intern (détection de fraude)

avr. 2026 – oct. 2026 · en cours

Malakoff Humanis — Paris · Périmètre : réseau optique (lentilles & lunettes) en assurance santé

- Détection de fraude sur prestations optiques : couverture du cycle complet, du besoin métier à la mise en production.
- Feature engineering métier et protection contre les fuites d'information ; classes d'âge apprises par arbres sur le train puis figées (train / test / API).
- Comparaison de modèles (régression logistique, Random Forest, XGBoost) en validation temporelle ; évaluation ROC-AUC, recall, F1, matrices de confusion et lift.
- Impact** : décile prioritaire ~79 % plus efficace qu'un contrôle aléatoire — ROC-AUC  $\approx 0,745$  et lift  $\approx 1,79$  (lentilles),  $0,695 / 1,70$  (lunettes).
- Industrialisation : pipelines MLflow autonomes (préparation + classification) testés dans l'API Dataiku DSS à partir des champs bruts.
- Monitoring hebdomadaire des variables clés (enrichissement temps réel de l'API) : clés manquantes, échecs, sorties absentes.
- Restitution aux équipes métier ; prototype de gouvernance du seuil de décision pour piloter le taux de contrôle.

### Gérant — commerce Bar-Tabac

en cours

Gestion des flux financiers et d'opérations sensibles dans le respect des procédures réglementaires ; relation client et organisation.

## PROJETS

### FraudScope AI — assistant d'investigation de fraude (GenAI + ML)

Python

Pipeline de scoring du risque de fraude (XGBoost / Random Forest / régression logistique, sélection par score robuste, lift par décile) couplé à un agent GenAI (RAG hybride dense+BM25, function calling, LangGraph) qui explique le score et cite les règles réglementaires applicables.

### Deep Learning & NLP — parcours de projets (from scratch → Transformers)

Python · PyTorch

Parcours progressif en deep learning appliqué au NLP : réseaux from scratch (NumPy / PyTorch), word embeddings, RNN / LSTM, Transformers (attention, fine-tuning CamemBERT) et pipeline RAG (FAISS, embeddings sémantiques).

**GovProcure AI** — Python · Plateforme d'analyse des marchés publics français (3,14M contrats open data) : contrôle qualité, détection d'anomalies (Isolation Forest / LOF) et recherche hybride BM25 + embeddings + RRF ; 69 tests, CI GitHub Actions.

**Séries temporelles** — Python · Étude de stationnarité (ACF / PACF), modélisation ARIMA / SARIMA, prévision et backtesting sur données réelles.

**Modélisation stochastique & propagation** — Python · Modèle épidémiologique SIR et ses extensions, phénomènes de percolation sur graphes, simulations Monte-Carlo et optimisation des paramètres.

## FORMATION

### Master 2 — Modélisation et Méthodes Mathématiques en Économie et Finance (MMMEF), parcours Data

2024 – 2026

Université Paris 1 Panthéon-Sorbonne — en cours · Finance de marché et valorisation, gestion des risques, économétrie, pricing d'options et méthodes numériques, optimisation, séries temporelles, data science.

### Licence de Mathématiques (option informatique)

2021 – 2024

Université Paris-Saclay · Analyse, probabilités et statistiques, méthodes numériques, programmation Python.

## COMPÉTENCES & CENTRES D'INTÉRÊT

**Modélisation & risque** : modélisation statistique, scoring du risque, gestion des risques, PSI / dérive, apprentissage sensible aux coûts, KRI, suivi de la performance.

**Outils** : Python (pandas, NumPy, Scikit-learn, XGBoost), R, SQL, Snowflake, Dataiku DSS, MLflow, Power BI, Git.

**Domaine** : assurance, santé / prévoyance, détection de fraude, tarification, souscription, conformité.

**Soft skills** : rigueur analytique, sens des responsabilités, synthèse, prise de décision, communication.

**Centres d'intérêt** : IA & data · finance et économie · veille technologique · badminton · musculation (1 séance/semaine) · voyages.